

Subject :

Year . Month . Date .

* Session 10 : CSP

- در این جلسه می خواهیم کاربرد دیگری از مطالب گفته شده در ماشین نرینگ

را بررسی کنیم. مسئله ماشین نرینگ BCI را به صورت زیر تعریف می کنیم :

* Brain Comp. Interface (BCI)

مسئله ماشین نرینگ را به این صورت تعریف می کنیم که قرار است از سیگنال های دریافت

شده از سنسورهای مغز استفاده شده روی سر متوجه جهت حرکت (راست و چپ) شویم.

برای حل این مسئله از الگوریتم CSP استفاده می کنیم :

Common Spatial Pattern \rightarrow CSP

- فرض کنیم در مرحله train (آفرینش) دو ماتریس مشاهدات یکی مربوط به چپ و دیگری

به سمت راست و دیگری سمت چپ دریافت می کنیم. X_1^l و X_1^r


باید یک ویژگی در دو ماتریس مشاهدات بدست آوریم تا حرکت به چپ و راست را از هم

تمایز کنیم. به این منظور یک بردار (W) را از چپ در بردار مشاهدات ضرب می کنیم و

Subject :

Year . Month . Date .

صوری این w را تعیین می کنیم که واریانس بدست آمده برای هر حرکت مجزوه طاقلاً متفاوتی داشته باشد.



* حال تابع هدف $f(w)$ را بصورت زیر تعریف می کنیم:

$$f(w) = \frac{\|w^T X_1^r\|^2}{\|w^T X_1^e\|^2} = \frac{w^T X_1^r X_1^{rT} w}{w^T X_1^e X_1^{eT} w} = \frac{w^T R_x^r w}{w^T R_x^e w}$$

* در صورتی که چندین مشاهده (train های دیگری) هم داشته باشیم:

$$R_x^{(r)} = \frac{1}{N_r} \sum_{n=1}^{N_r} X_n^r X_n^{rT}, \quad R_x^{(e)} = \frac{1}{N_e} \sum_{n=1}^{N_e} X_n^e X_n^{eT}$$

صافین $\leftarrow N_r$

$$\rightarrow f(w) = \frac{w^T R_x^{(r)} w}{w^T R_x^{(e)} w}, \quad \text{s.t. } w^T w = 1$$

$$\nabla_w f = \frac{2R_x^{(r)} w (w^T R_x^{(e)} w) - 2R_x^{(e)} w (w^T R_x^{(r)} w)}{0^2} = 0$$

Batus

Subject :

Year . Month . Date .

$$\rightarrow R_x^{(r)} w (w^T R_x^{(e)} w) = \lambda R_x^{(e)} w (w^T R_x^{(r)} w)$$

$$\rightarrow R_x^{(r)} w = \frac{(w^T R_x^{(r)} w)}{(w^T R_x^{(e)} w)} R_x^{(e)} w$$

نسبت کلی

$$\rightarrow R_x^{(e)-1} R_x^{(r)} w = \lambda w$$

Generalized EVD (GEVD)

نه این حال هم مقدار بردار ویژه برای مایکروس

$$\Rightarrow [U, \Lambda] = \text{eig}(R_x^{(r)}, R_x^{(e)})$$

در محیط مقاب

$$\begin{array}{ccccccc} \Lambda & \Rightarrow & \lambda_1 & > & \lambda_2 & > & \dots & > & \lambda_n \\ & & \downarrow & & \downarrow & & & & \downarrow \\ U & \Rightarrow & u_1 & & u_2 & & & & u_n \\ & & \downarrow & & & & & & \downarrow \\ & & w_1 & & & & & & w_n \end{array}$$

در حقیقت ویژگی استخراج شده از بردار $w^T X_1$ واریانس (انرژی) آن بوده در

ماشین برنیگ بهترین است چند ویژگی را استخراج کنیم

$$w^T X_1 \xrightarrow{\text{فشرده سازی}} \sigma_1^2 \Rightarrow \text{بسیاری اطلاعات در فشرده سازی از دست رفته است}$$

Subject :

Year . Month . Date .

* نکته: در دستور w بدست آمده، عنصر مربوط به هر سنسور را به دست می آوریم و

کل w را بهم می انیم. هر کدام مقدار بزرگتری داشت یعنی در واریانس بیشتری داشته و

می توانیم از آن سنسور در سر استفاده کنیم. (به جای w سنسور همان سنسور را استفاده کنیم).

* می توانیم برعکس ویژگی ۱، این بار w را طوری تعریف کنیم که واریانس کمتری به

چپ خلی بزرگتر از واریانس حرکت به راست شود.

* ویژگی ۱: تعریف w : $\text{var}(w^T X_i^{(e)}) \gg \text{var}(w^T X_i^{(r)})$


* ویژگی ۲: تعریف w : $\text{var}(w^T X_i^{(e)}) \ll \text{var}(w^T X_i^{(r)})$

مراحل بدست آوردن w برای ویژگی ۲ مثل ویژگی ۱ طی می شود با این تفاوت که تابع هدف

عکس $\frac{1}{f(w)}$ می شود. یعنی ماکزیمم ویژگی ۲، مینیمم ویژگی ۱ می شود پس از خروجی تابع

eig می توانیم w_m را به عنوان ویژگی ۲ استخراج کنیم.

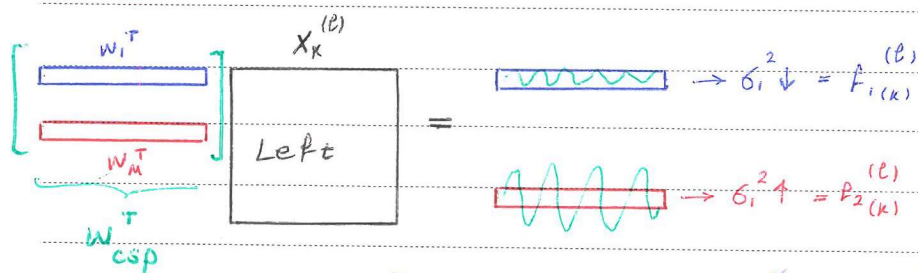

$$[U, \Lambda] = \text{eig}(R_x^{(r)}, R_x^{(e)})$$




Batus

Subject :

Year . Month . Date .




* در نتیجه فضای ویژگی (2) هر دو ویژگی به صورت زیر می شود :



در الگوریتم CSP تعداد زوج ویژگی انتخاب می کنیم و در w_{csp} قرار می دهیم مثلاً :

$$w_{csp} = [w_1 \ w_2 \ ; \ w_{m-1} \ w_m]$$



Batus

Subject :

Year . Month . Date .

2m Features

* در حالت کلی اگر 2m ویژگی داشته باشیم.

$$W_{\text{esp}}_{M \times 2m} = [w_1, w_2, \dots, w_m \mid w_{m+1}, \dots, w_{m-1}, w_m]$$

بعد از استخراج ویژگی باید داده ها را کلاس بندی کنیم. یعنی مرز ویژگی ها را مشخص

کنیم.

* طبقه بندی: * Linear Discriminant analysis (LDA)

طبقه بندی خطی: دو کاری کنند: ① میانگین ها را از هم دور می کنند.

② واریانس ها را کم می کنند.

حال ابتدا رابطه میانگین ها و واریانس ها را بدست می آوریم:

$$\mu^{(1)} = \frac{1}{N_1} \sum_{t=1}^{N_1} W_{\text{LDA}}^T x^{(1)}(t) = W_{\text{LDA}}^T \underbrace{\left(\frac{1}{N_1} \sum_{t=1}^{N_1} x^{(1)}(t) \right)}_{\mu_1} = W_{\text{LDA}}^T \mu_1$$

$$\mu^{(1)} = W_{\text{LDA}}^T \mu_1, \quad \mu^{(2)} = W_{\text{LDA}}^T \mu_2$$

$$\sigma^{(1)} = \frac{1}{N_1} \sum_{t=1}^{N_1} (W_{\text{LDA}}^T x^{(1)}(t) - \mu^{(1)})^2$$

$$= \frac{1}{N_1} \sum_{t=1}^{N_1} (W_{\text{LDA}}^T (x^{(1)}(t) - \mu_1) (x^{(1)}(t) - \mu_1)^T W_{\text{LDA}})$$

Batus

Subject :

Year . Month . Date .

$$\rightarrow \sigma^{2(1)} = W_{LDA}^T \left[\underbrace{\frac{1}{N_1} \sum_{t=1}^{N_1} (x^{(1)}(t) - \mu_1)(x^{(1)}(t) - \mu_1)^T}_{\Sigma_1} \right] W_{LDA}$$

$$\oplus \rightarrow \Sigma_1 = \frac{1}{N_1} \sum_{t=1}^{N_1} (x^{(1)}(t) - \mu_1)(x^{(1)}(t) - \mu_1)^T$$

$$\sigma^{2(1)} = W_{LDA}^T \Sigma_1 W_{LDA} \quad , \quad \sigma^{2(2)} = W_{LDA}^T \Sigma_2 W_{LDA}$$

$$f(W_{LDA}) = \frac{(\mu^{(1)} - \mu^{(2)})^2}{\sigma^{2(1)} + \sigma^{2(2)}} = \frac{(W_{LDA}^T \mu_1 - W_{LDA}^T \mu_2)^2}{W_{LDA}^T \Sigma_1 W_{LDA} + W_{LDA}^T \Sigma_2 W_{LDA}}$$

$$= \frac{W_{LDA}^T (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T W_{LDA}}{W_{LDA}^T (\underbrace{\Sigma_1 + \Sigma_2}_{\Sigma}) W_{LDA}}$$

بردار ویژه مضارب
برگشتن مقدار در $W_{LDA} = GEVD(\oplus, \otimes)$

در محیط خطی
↓
eig

$$[U, \Lambda] = eig(\oplus, \otimes) \Rightarrow \begin{array}{c} \lambda_1 > \lambda_2 > \dots > \lambda_m \\ \downarrow \quad \quad \quad \downarrow \\ u_1 \quad \quad \quad u_m \\ \downarrow \quad \quad \quad \downarrow \\ W_{LDA} \end{array}$$

Batus

Subject :

Year . Month . Date .

* برای اینکه مرز بین دو گروه را مشخص کنیم باید یک آستانه (thr) تعیین کنیم بهترین

گزینه ، میانگین میانگین دو گروه است ، یعنی :

$$thr = \frac{1}{2} (\mu^{(1)} + \mu^{(2)})$$

* جلسه یازدهم :

* بارشود $f.p.t$ در مطلب :

$x(t)$ =



Batus